电子商务导论

第5章 使用Scikit-Learn进行商务数据挖掘

朱桂祥 (9120201070@nufe.edu.cn)
南京财经大学信息工程学院
江苏省电子商务重点实验室
电子商务信息处理国家级国际联合研究中心
电子商务交易技术国家地方联合工程实验室

清华大学校训

---易经乾卦《象》曰：天行健，君子以自强不息。

---易经坤卦《象》曰：地势坤，君子以厚德载物。

君子自励犹如天体之运行刚健不息，不得一曝十寒，不应见利而进，知难而退，而应重自胜摈私欲尚果毅，不屈不挠，见义勇为，不避艰险，自强不息；同时，君子应如大地的气势厚实和顺，容载万物，责己严，责人轻，以博大之襟怀，吸收新文明，改良我社会，促进我政治，以宽厚的道德，担负起历史重任。

目 录
Contents

一、Scikit-Learn简介

1. 知识框架图

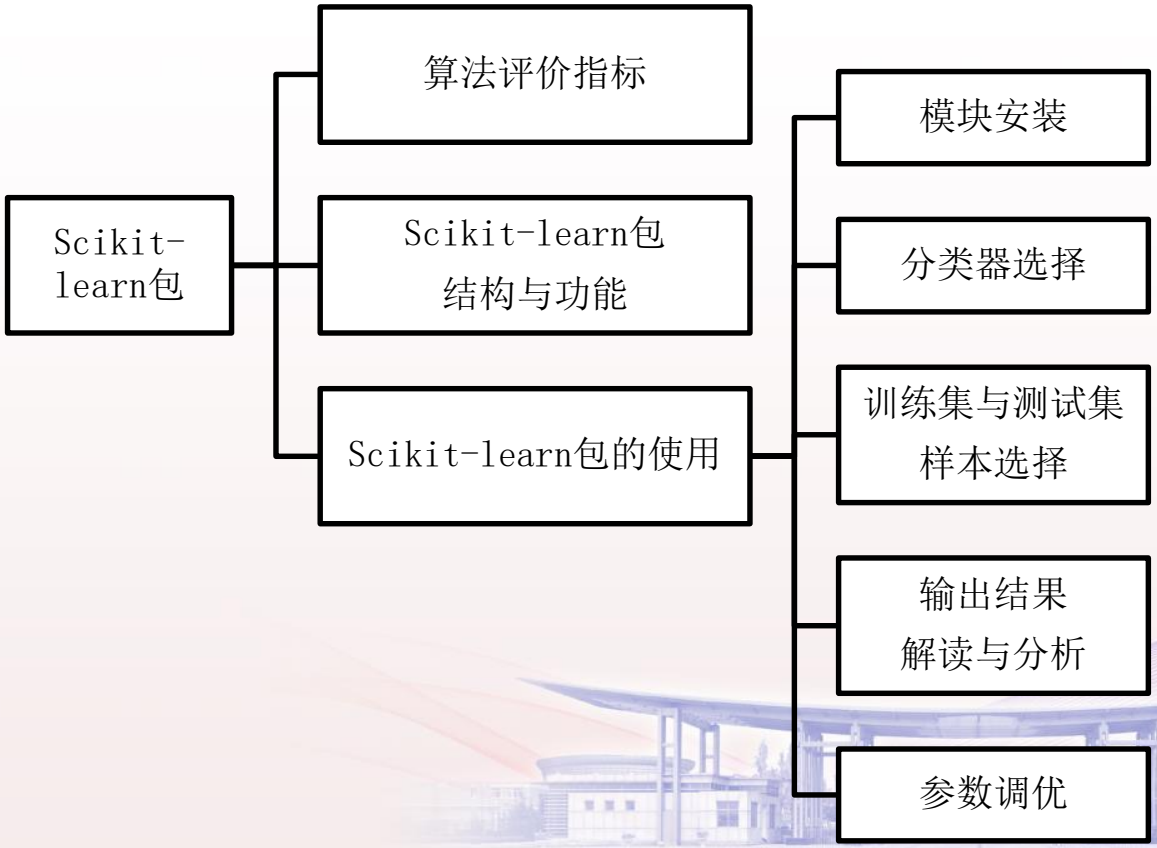

一、Scikit-Learn简介

2. Scikit-Learn的主要功能

- Scikit-Learn项目是由数据科学家 David Cournapeau 于 2007 年发起的，它目前已经成了Python语言中专门针对机器学习应用的一款开源框架，几乎覆盖了机器学习的所有主流算法。
- 其官方网址为http://Scikit-Learn.org/stable/ ，如下图所示。

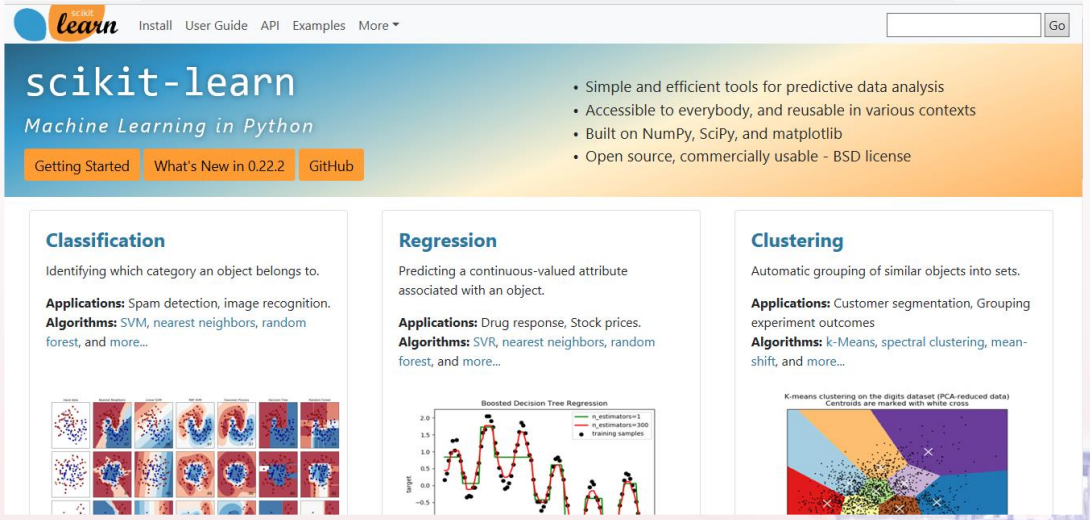

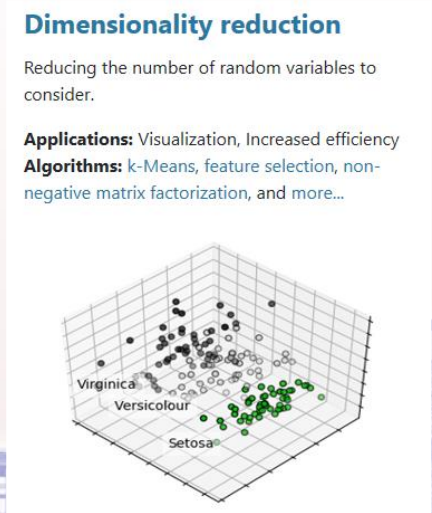

一、Scikit-Learn简介

2. Scikit-Learn的主要功能

- 作为数据挖掘算法分析、设计和实施的开发人员，通常希望能够掌握算法的具体思路、实现流程和参数调优。
- 但对于参与金融数据挖掘工作的金融业务人士而言，他们可能并不关注算法的实现细节，而更关注如何从业务分析的角度来选择重要的数据属性和合适的算法。
- Scikit-Learn为金融数据挖掘算法开发人员和金融业务专家参与算法与模型分析的人士提供了一个共同的接口，它是目前广受欢迎的简单高效的数据挖掘和数据分析工具。

一、Scikit-Learn简介

2.Scikit-Learn的主要功能

- **Scikit-Learn的主要功能包括如下六个方面：**
  - **（1）Classification（分类）**
  - **（2）Regression（回归）**
  - **（3）Clustering（聚类）**
  - **（4）Dimensionality Reduction**
  - **（5）Model Selection**
  - **（6）Preprocessing（数据预处理）**

一、Scikit-Learn简介

3. Scikit-Learn安装

- 使用Scikit-Learn进行数据挖掘时需要NumPy和SciPy等包的支持，因此在安装Scikit-Learn之前需要安装这些支持包。
- 请读者通过网址http://Scikit-Learn.org/stable/install.html查看Scikit-Learn的官方文档 ，了解所需安装的支持包具体列表和教程。
- 如果本机安装了Anaconda，则系统已默认安装好Scikit-Learn相关的包。
- 如果本机安装的是Miniconda，则用户需要运行以下命令来完成Scikit-Learn的安装：
- conda install Scikit-Learn

一、Scikit-Learn简介

3. Scikit-Learn安装

- 另外，通过Jupyter Notebook工具也可运行Scikit-Learn样例。
- 先从官方提供的样例库（http://Scikit-Learn.org/stable/auto_examples/index.html#general-examples）中选择一个样例，在该页面中下载其Python源码或者IPython notebook文件，将这些下载好的文件置于Jupyter Notebook运行就可以看到样例的结果。

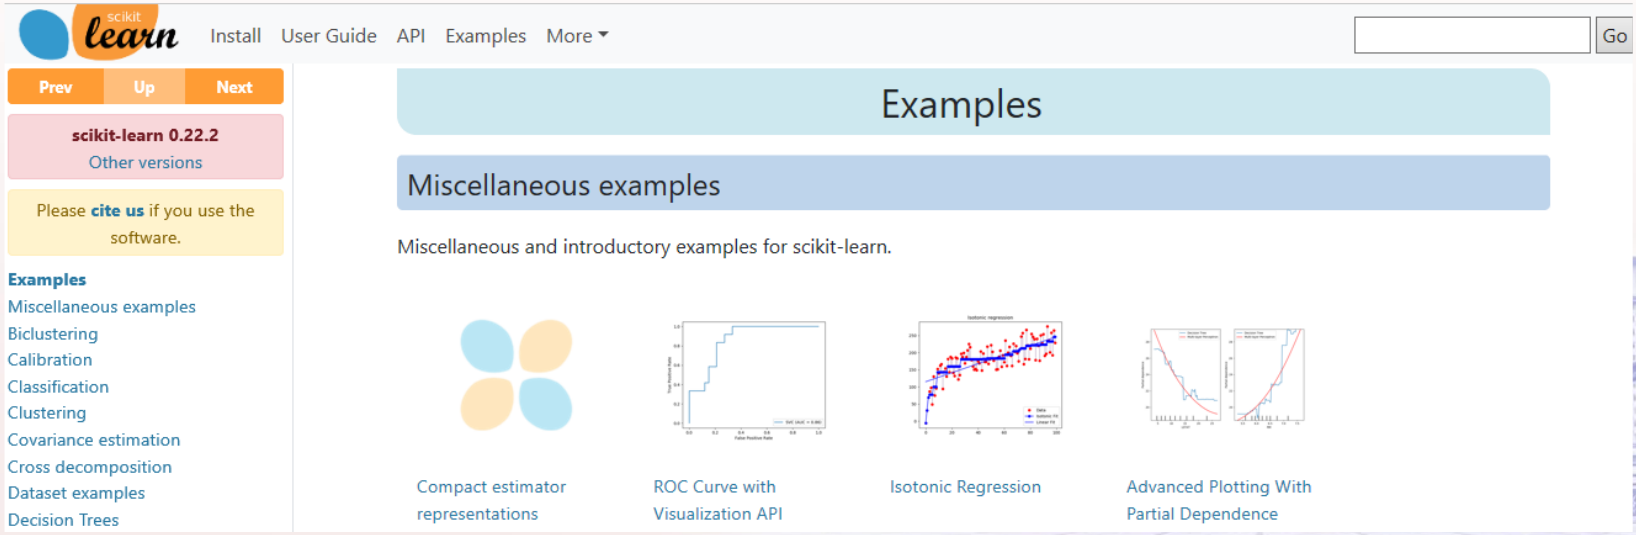

二、使用Scikit-Learn进行数据挖掘

1. 数据挖掘的基本流程：

(1)Look at the big picture：进行整体宏观考察，确定项目需求、目标和整体路径。

(2)Get the data：获取数据，可能来自于已有数据，也可能需要重新采集。

(3)Discover and visualize the data to gain insights：借助图表深入发现了解数据，可以通过Pandas读入数据文件，借助Matplotlib或者Seaborn绘制图表。

(4)Prepare the data for Machine Learning algorithms：进行数据整理（填充缺失值、处理异常/离群值、非数值型转换为数值型等）、属性选择（发现属性之间的相关性，进行重点分析，还可以通过丢弃非相关/弱相关属性，降低计算工作量）、训练集/测试集分离（选择部分数据用于训练算法模型，另一部分数据用于测试检查训练好的模型效果）等。

二、使用Scikit-Learn进行数据挖掘

1. 数据挖掘的基本流程：

(5)Select a model and train it：选择合适的数据挖掘模型，从各种数据挖掘算法中进行选择和尝试，并进行训练。

(6)Fine-tune your model：模型参数调优，进一步提升算法模型的效果。

(7)Present your solution.：提交解决方案。

(8)Launch, monitor, and maintain your system：发布、监控和维护系统。

二、使用Scikit-Learn进行数据挖掘

2. **Scikit-Learn的主要模块：**

- ✓ 预处理器（Sklearn Prepressing）：预处理主要分为规范化和编码，规范化主要包括最大最小值规范化（MinMaxScaler）、归一化（Normalize，使特征值和为1）和白化（StandartScaler，使特征值均值为0，方差为1）；编码主要包括LabelEncoder（字符串转化为整型）、OneHotEncoder（特征由一个二进制数字表示）、Binarizer（特征二值化）和MultiLabelBinarizer（多标签二值化）等。
- ✓ 转换器（Transformer）：用于数据预处理和数据转换。
- ✓ 估计器（Estimator）：估计器实际上就是封装成类的各种数据挖掘算法。每个算法都支持两个函数：fit(x,y) 和 predict(x)，分别用于训练和预测。以分类估计器为例，函数fit(x,y)中的x是训练集（没有分类标签），y则是x对应的分类标签，其参数格式均为numpy数组或类似格式。
- ✓ 模型评估（度量），交叉验证：主要包含评分方法，性能度量，成对度量和距离计算等。

二、案例

1. 案例：房地产区域价格分析

- 通过抽样调查得到美国加利福利亚州的房屋价格数据（其部分数据如下表所示）。采集的字段包括房屋坐落区域经纬度、该区域的样本房屋使用年限中位数、样本房屋房间总数、样本房屋卧室总数、人口数量、样本户数、收入中位数、离海滩距离和样本房价中位数等。

longitude	latitude	housing_ median_ age	total_ rooms	total_ bedrooms	Popu lation	House holds	median_ income	ocean_ proximity	median_ house_ value
-122.23	37.88	41	880	129	322	126	8.3252	NEAR BAY	452600
-122.22	37.86	21	7099	1106	2401	1138	8.3014	NEAR BAY	358500
-122.24	37.85	52	1467	190	496	177	7.2574	NEAR BAY	352100
-122.25	37.85	52	1274	235	558	219	5.6431	NEAR BAY	341300
.....									

二、案例

1. 案例：房地产区域价格分析

本案例的任务是使用Python数据挖掘工具实现一个能以前9列数据为输入，以median_house_value为预测目标输出的模型。

In[1]:

```
import pandas as pd
import numpy as np

#加利福利亚房价数据
caDF = pd.read_csv('california_housing.csv')
print(caDF.shape)
print('加州房价数据前 5 行：')
print(caDF.head())

#观察数据，发现存在缺失值和非数值型字段
sample_incompletedata = caDF[caDF.isnull().any(axis=1)]
print('存在缺失值的数据前 5 行：')
print(sample_incompletedata.head())

#因为 total_rooms 和 total_bedrooms 线性相关性较强，
#为了减少运算量，将 total_bedrooms 列舍去
caDF.drop(['total_bedrooms'],axis=1,inplace=True)

#ocean_proximity 列是文本标签，描述了房屋离海滩距离
#使用 LabelEncoder 将文本标签转换为数值标签
from sklearn.preprocessing import LabelEncoder
caDF[['ocean_proximity']]=caDF[['ocean_proximity']].apply\
                                    (LabelEncoder().fit_transform)

#使用 SkLearn 的 Imputer 处理缺失数据
from sklearn.impute import SimpleImputer
imputer = SimpleImputer(strategy="median") #用该列中位数填充缺失值
imputer.fit(caDF)
#将所有数据转换为 float 类型
caDF=pd.DataFrame(caDF,dtype=np.float)
print('整理后数据前 5 行，请注意比原始数据少了一列：')
print(caDF.head())

#分离训练集与测试集，median_house_value 列的数据是研究的目标
from sklearn.model_selection import train_test_split
caDFdata=caDF.drop(['median_house_value'],axis=1)
caDFprice=caDF['median_house_value']
Train_X,Test_X,Train_y,Test_y=train_test_split(caDFdata,caDFprice,
                                    test_size=0.2,random_state=42)

#数据标准化,将每一列数据转换为均值为 0，方差为 1 的数据，
#便于后续处理
from sklearn.preprocessing import StandardScaler
ss= StandardScaler().fit(Train_X)
Train_X = pd.DataFrame(ss.transform(Train_X), columns=Train_X.columns)
Test_X  = pd.DataFrame(ss.transform(Test_X),  columns=Test_X.columns)

print('标准化后训练集前 5 行：')
print(Train_X.head())
```

二、案例

1. 案例：房地产区域价格分析

- 输出结果：

Out: (20640, 10)

加州房价数据前 5 行：

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	\
0	-122.23	37.88	41.0	880.0	129.0	
1	-122.22	37.86	21.0	7099.0	1106.0	
2	-122.24	37.85	52.0	1467.0	190.0	
3	-122.25	37.85	52.0	1274.0	235.0	
4	-122.25	37.85	52.0	1627.0	280.0	

	population	households	median_income	median_house_value	ocean_ proximity
0	322.0	126.0	8.3252	452600.0	NEAR BAY
1	2401.0	1138.0	8.3014	358500.0	NEAR BAY
2	496.0	177.0	7.2574	352100.0	NEAR BAY
3	558.0	219.0	5.6431	341300.0	NEAR BAY
4	565.0	259.0	3.8462	342200.0	NEAR BAY

存在缺失值的数据前 5 行：

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	\
290	-122.16	37.77	47.0	1256.0	NaN	
341	-122.17	37.75	38.0	992.0	NaN	
538	-122.28	37.78	29.0	5154.0	NaN	
563	-122.24	37.75	45.0	891.0	NaN	
696	-122.10	37.69	41.0	746.0	NaN	

	population	households	median_income	median_house_value	ocean_ proximity
0	290	570.0	218.0	4.3750	NEAR BAY
1	341	732.0	259.0	1.6196	NEAR BAY
2	538	3741.0	1273.0	2.5762	NEAR BAY
3	563	384.0	146.0	4.9489	NEAR BAY
4	696	387.0	161.0	3.9063	NEAR BAY

整理后数据前 5 行，请注意比原始数据少了一列：

	longitude	latitude	housing_median_age	total_rooms	population	\
0	-122.23	37.88	41.0	880.0	322.0	
1	-122.22	37.86	21.0	7099.0	2401.0	
2	-122.24	37.85	52.0	1467.0	496.0	
3	-122.25	37.85	52.0	1274.0	558.0	
4	-122.25	37.85	52.0	1627.0	565.0	

	households	median_income	median_house_value	ocean_ proximity
0	126.0	8.3252	452600.0	3.0
1	1138.0	8.3014	358500.0	3.0
2	177.0	7.2574	352100.0	3.0
3	219.0	5.6431	341300.0	3.0
4	259.0	3.8462	342200.0	3.0

二、案例

1. 案例：房地产区域价格分析

标准化后训练集前 5 行：

	longitude	latitude	housing_median_age	total_rooms	population	\
0	1.272587	-1.372811	0.348490	0.222569	0.768276	
1	0.709162	-0.876696	1.618118	0.340293	-0.098901	
2	-0.447603	-0.460146	-1.952710	-0.342597	-0.449818	
3	1.232698	-1.382172	0.586545	-0.561490	-0.007434	
4	-0.108551	0.532084	1.142008	-0.119565	-0.485877	

	households	median_income	ocean_proximity
0	0.322906	-0.326196	2.005932
1	0.672027	-0.035843	2.005932
2	-0.430461	0.144701	2.005932
3	-0.380587	-1.017864	2.005932
4	-0.314962	-0.171488	-0.112427

第10-13行检查是否存在缺失数据，并在第25-28行进行了中位数填充缺失值；第15-17行通过人工分析，舍去了冗余的数据列；第19-23行将非数值数据转换为数值型数据；第41-46行将数据转换为均值为0、方差为1的标准化数据。这种处理对某些算法效果和执行效率有比较明显的提升

二、案例

1. 案例：房地产区域价格分析

- 其他算法的比较：随机森林回归，人工神经网络回归

In[2]:

```
#随机森林回归，是集成了多棵决策树而成的森林
from sklearn import ensemble
# 使用 20 个决策树
model_rf= ensemble.RandomForestRegressor(n_estimators=20)
model_rf.fit(Train_X,Train_y)
rf_score=model_rf.score(Test_X,Test_y)*100
print('sklearn 随机森林模型得分: %.1f %rf_score + '%')
rf_pred=model_rf.predict(Test_X)
```

Out: sklearn 随机森林模型得分: 80.6%

使用随机森林模型来对影响因素（即前 9 列的数据）和结果（即最后的房价中位数）进行回归拟合。随机森林模型是集成了多棵决策“树”而成的“森林”。这种模型往往能在拟合求解速度和模型效果之间取得较好的平衡。

In[3]:

```
#人工神经网络回归，Sklearn 中，又称多层感知机 MLP
from sklearn.neural_network import MLPRegressor
model_mlp = MLPRegressor(solver='lbfgs', hidden_layer_sizes=(5, 5),
                         random_state=1)
model_mlp.fit(Train_X,Train_y)
mlp_score=model_mlp.score(Test_X,Test_y)*100
print('sklearn 人工神经网络回归模型得分: %.1f %mlp_score + '%')
```

Out: sklearn 人工神经网络回归模型得分: 69.0%

使用随机森林模型来对影响因素（即前9列的数据）和结果（即最后的房价中位数）进行回归拟合。随机森林模型是集成了多棵决策“树”而成的“森林”。这种模型往往能在拟合求解速度和模型效果之间取得较好的平衡。

使用Scikit-Learn中的人工神经网络（在Scikit-Learn中又称多层感知机MLP）来拟合则效果略差。若借助Scikit-Learn调整模型参数，则可以进一步提升效果。

二、案例

1. 案例：房地产区域价格分析

- 人工神经网络的优化：
- 加大神经网络中隐藏层节点的个数可以提升算法的学习效果。若进一步加大'hidden_layer_sizes': [(5,5),(10,10)]的搜索范围，则还可能进一步提升学习效果，但需要更多的计算能力和运行时间。

In[4]:

```
#采用 GridSearchCV 来进行参数调整实验，找出最佳参数组合
from sklearn.model_selection import GridSearchCV
param_grid = {'solver':['lbfgs','sgd','adam'],
                    'hidden_layer_sizes': [(5,5),(10,10)]
                   }
#对 param_grid 中的各参数进行组合，传递进 MPL 回归器。
#cv=3,3 折交叉验证，将数据集随机分为 3 份，
#每次将一份作为测试集，其他为训练集
#n_jobs=-1，使用 CPU 核心数，-1 表示所有可用的核
best_mlp =GridSearchCV(MLPRegressor(max_iter=200),
                                                param_grid,cv=3,n_jobs=-1)
best_mlp.fit(Train_X,Train_y)
print('当前最佳参数组合：',best_mlp.best_params_)
best_score=best_mlp.score(Test_X,Test_y)*100
print('sklearn 人工神经网络上述参数得分: %.1f' %best_score + '%')
#用以上模型对 Test_X 进行预测
      mlp_pred = best_mlp.predict(Test_X)
```

Out:

```
当前最佳参数组合：  {'hidden_layer_sizes': (10, 10), 'solver': 'lbfgs'}
sklearn 人工神经网络上述参数得分: 73.5%
```

二、案例

1. 案例：房地产区域价格分析

- 绘图比较模型预测房价与真实房价的差异：

```
#绘图比较模型预测房价与真实房价的差异
import matplotlib.pyplot as plt
from matplotlib import rcParams
plt.rcParams['font.sans-serif']=['SimHei']
plt.rcParams['axes.unicode_minus'] = False
fig = plt.figure(figsize=(10, 6))   # dpi 参数指定绘图对象的分辨率，即每英寸多少个像素，缺省值为 80
#axes = fig.add_subplot(1, 1, 1)
#为便于观察，只取部分结果作图
T1=Test_y[:50]
P1=mlp_pred[:50]
R1=rf_pred[:50]
plt.plot(range(len(T1)),T1, 'g',label='实际',linewidth=3)
plt.plot(range(len(P1)),P1, 'y--',label='神经网络回归',linewidth=2)
plt.plot(range(len(P1)),R1, 'r:',label='随机森林回归',linewidth=2)
fig.tight_layout()
plt.legend()
plt.title('sklearn  回归模型')
plt.savefig('skl_01.png',dpi=300,bbox_inches='tight')
        plt.show()
```

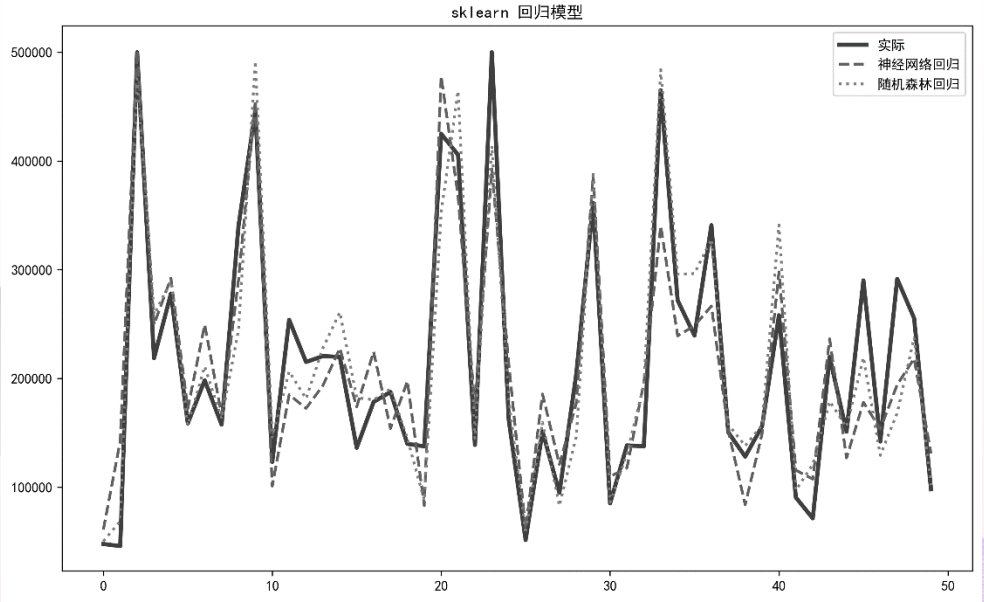

该图直观地展示了两种模型对测试集中数据的预测值及算法效果的差异。

谢谢观赏 下节课见